

Rapport de Projet : Distillation de Modèles de Raisonnement (DASD)

DELAUW Valentin - QUARANTA Nicolas

1. Introduction

Dans le cadre de ce projet sur la Distillation de Modèles de Raisonnement en utilisant la méthode DASD (Distribution-Aligned Sequence Distillation), nous avons cherché à transférer les capacités approfondies d'analyse "Chain-of-Thought" (CoT) d'un large modèle ("Teacher") vers un modèle beaucoup plus léger et déployable localement ("Student" : [Qwen3-4B-Instruct](#)).

Pour rendre le projet plus concret, nous avons choisi de l'appliquer à un cas d'usage complexe et stratégique : l'assistance à la phase de "draft" (sélection et bannissement des champions) dans *League of Legends*. Dans ce jeu, la phase de draft est une étape cruciale où chaque équipe choisit ses personnages en fonction des choix et bannissements de l'adversaire, dans le but de construire la composition d'équipe la plus synergique et d'apporter les meilleurs "matchups".

L'objectif de notre modèle distillé est d'agir comme un véritable assistant stratégique : face à l'état actuel d'une draft (quels champions ont déjà été choisis, quels champions sont bannis), le modèle doit être capable de raisonner étape par étape pour évaluer les forces et faiblesses des compositions en cours, avant de déduire mathématiquement et stratégiquement le choix optimal (pick) à effectuer pour la suite.

2. Méthodologie

2.1 Synthèse du corpus et Génération du Dataset (Phases 1 et 2)

Afin d'obtenir un point de départ réaliste, nous nous sommes basés sur un dataset public Kaggle répertoriant de nombreux matchs de *League of Legends*. À partir de ces données brutes, nous avons extrait différentes situations de jeu sur lesquelles nous avons formulé des questions stratégiques.

Nous avons ensuite développé un pipeline de génération de données interrogeant un modèle puissant faisant office de "Teacher", via l'API d'Infomaniak. Pour appliquer la méthode DASD, ce "super dataset" a été généré en deux passes distinctes :

- **Stage 1 (Basse température, taux 0.3)** : Génération de réponses stables, structurées et très déterministes. Le but est d'apprendre au modèle étudiant la structure souhaitée : non seulement l'utilisation des balises `<reasoning>...</reasoning>` pour la chaîne de pensée, mais aussi le formatage strict de la réponse finale en **JSON**. Cela est primordial pour intégrer le modèle au sein d'une application ou d'un pipeline par la suite.

- **Stage 2 (Haute température, taux 0.9)** : Génération de réponses diversifiées, explorant différents fils de pensée stratégique sur *League of Legends*. Cela augmente la richesse de l'analyse produite.

2.2 Implémentation du Divergence-Aware Sampling (DAS) (Phase 4)

La génération à haute température de la Phase 2 produit de la diversité mais amène inévitablement du "bruit", voire des erreurs de jugement (hallucinations du modèle). C'est pour palier ce problème que nous avons implémenté le filtrage Divergence-Aware Sampling (DAS).

Plutôt que d'évaluer une réponse dans sa globalité, le script calcule la **divergence phrase par phrase** entre :

- Les probabilités linéaires du Teacher (P_T)
- Les probabilités linéaires du Student (P_S) testé sur la même situation.

Nous avons appliqué la matrice de décision du papier de recherche permettant de repérer les trois types de phrases :

1. **Teacher Sentences** ($P_T \gg P_S$) : Le Teacher est sûr de son raisonnement, mais l'Étudiant hésite. L'apport pédagogique est fort. C'est ici que l'étudiant a tout à apprendre de son professeur. -> **CONSERVÉ**
2. **Shared Sentences** ($P_T \approx P_S$) : Comportement neutre, l'étudiant maîtrise déjà l'idée. -> **NEUTRE**
3. **Student Sentences** ($P_S > P_T$) : L'étudiant a trop d'assurance sur une idée où le Teacher doute, il s'agit d'une potentielle hallucination. -> **REJETÉ**

Grâce à cet algorithme, nous avons pu nettoyer le dataset de la Phase 2 pour ne garder que les exemples comportant une véritable "leçon" pour notre modèle.

2.3 Configuration de l'entraînement (Phase 5)

Nous avons utilisé Llama-Factory pour paramétrer le fine-tuning (via un adaptateur LoRA) du modèle de base **Qwen3-4B-Instruct**. Conformément à la méthodologie DASD, nous avons scindé l'entraînement (Config 5) :

- **Stage 1** : Entraînement sur le dataset "Basse Température" pour stabiliser l'apprentissage global du format.
- **Stage 2** : Reprise des poids de l'adaptateur obtenu en fin de Stage 1, puis entraînement sur le dataset Haute Température filtré par le DAS.

3. Résultats et Analyse (Phase 7)

3.1 Entraînement et performances numériques

Les différents runs d'entraînement ont été effectués avec succès. Voici les performances chiffrées issues des logs du framework d'entraînement:

- **Stage 1** : L'entraînement s'est fait sur 3 époques. La fonction de perte sur l'entraînement (**train_loss**) est descendue à environ **0.657**, tandis que la loss sur

le set de validation est très prometteuse avec **0.468**. Cela indique une très bonne assimilation du format de base sans overfitting grossier.

- **Stage 2** : Le second apprentissage sur 2 époques a affiché une excellente stabilité. La loss d'entraînement plafonne avec consistance autour de **0.650**.

3.2 Analyse des courbes


Vous trouverez ci-dessous les graphiques de suivi de loss correspondants aux deux étapes d'apprentissage.

Graphes du Stage 1 :



Analyse : Lors de cette première étape, on observe une descente initiale rapide de la loss qui traduit la phase d'adaptation rapide de Qwen-4B aux instructions spécifiques (notamment le formatage en `<reasoning>`). La courbe montre une belle stabilité au fil des itérations, indiquant que le format déterministe est bien appris.

Graphes du Stage 2 :



Analyse : La courbe de ce second stage, bien qu'un peu plus bruitée du fait de la complexité des raisonnements explorés (dataset haute température filtré), reste stable. Il n'y a pas de rebond explosif de la loss, ce qui prouve que la méthode de filtrage DAS remplit bien son rôle : le bruit néfaste a été retiré, ne conservant qu'un apprentissage progressif de la profondeur stratégique.

4. Discussion et Limites

4.1 Réussites du projet

La méthode DASD se démontre particulièrement efficace. Au lieu de demander à un petit modèle de 4B de "réinventer la roue" stratégique, la distillation nous a permis d'instiller la logique implacable de modèles cent fois plus lourds. Le fait de fonctionner sur des données métier de jeu a prouvé qu'un "petit" LLM, une fois bien cadré, ne se perd plus dans des banalités et déroule véritablement un processus de décision séquentiel.